

## Reconocimiento de Patrones

Version 2023-2

# MÁQUINAS DE SOPORTE VECTORIAL

Dr. José Ramón Iglesias  
DSP-ASIC BUILDER GROUP  
Director Semillero TRIAC  
Ingeniería Electrónica  
Universidad Popular del Cesar

# Objetivos

Identificar el método de funcionamiento de una máquina de soporte vectorial.

Reconocer el principio de funcionamiento del truco del kernel.

Usar una SVM en el problema de clasificación binaria.

## Que son:

Son un conjunto de métodos de aprendizaje supervisado para la clasificación y regresión.

Viendo los datos de entrada como conjuntos de vectores en un espacio  $n$ -dimensional, una SVM construirá un hiper plano de separación en ese espacio, que maximiza el margen entre los conjuntos de datos.


Se hicieron populares por su éxito en reconocimiento de dígitos manuscritos

# Historia:

[https://scholar.google.com/citations?user=U\\_IVY50AAAJ&hl=en](https://scholar.google.com/citations?user=U_IVY50AAAJ&hl=en)

<https://scholar.google.com/citations?user=vtegaJgAAA&hl=en>


# Idea:



Por ejemplo:


Separar en este caso dos clases con una línea recta

# Idea:




Se puede  
así

# Idea:



Se puede  
poner  
también así


# Idea:



O así




# Idea:




O así

Idea:




?

# Idea:



La línea que  
tenga un mayor  
margen será la  
escogida para  
clasificar

# Idea:



Los limites que  
toca este margen  
son llamados:

**VECTORES DE  
SOPORTE**

# Maquinas de soporte vectorial lineales

## Caso separable

Dadas  $m$  observaciones:

Con un vector de características  $x_i \in R^n, i = \{0 \dots m - 1\}$

Y unas etiquetas  $y_i \in \{+1, -1\}$

# Maquinas de soporte vectorial lineales

Supóngase que se tiene un hiperplano que separa unas muestras etiquetadas (+1) de las otras (-1). Los puntos  $\mathbf{x}$  en el hiperplano satisfacen  $\mathbf{w} \cdot \mathbf{x} - b = 0$ .

$\mathbf{w}$  es un vector normal al hiper plano.

$\|\mathbf{w}\|$  es la norma euclidiana de  $\mathbf{w}$

$\frac{|-b|}{\|\mathbf{w}\|}$  es la distancia perpendicular del hiperplano al origen.

# Maquinas de soporte vectorial lineales

Supongamos que el conjunto de datos satisface:


$$(\mathbf{w} \cdot \mathbf{x}_i) - b \geq 1 \text{ si } y_i = 1 \quad (\mathbf{w} \cdot \mathbf{x}_i) - b = 1 \text{ con una distancia al origen de } \frac{|b|}{\|\mathbf{w}\|}$$

$$(\mathbf{w} \cdot \mathbf{x}_i) - b \leq -1 \text{ si } y_i = -1 \quad (\mathbf{w} \cdot \mathbf{x}_i) - b = -1 \text{ con una distancia al origen de } \frac{|b|}{\|\mathbf{w}\|}$$

Multiplicando  $y_i$  a ambos lados de ambas ecuaciones pero simplificando solo en la derecha:

$$y_i((\mathbf{w} \cdot \mathbf{x}_i) - b) - 1 \geq 0$$

# Maquinas de soporte vectorial lineales



Por lo que las distancias  $d_+$  y  $d_-$  están dadas por :

$$d_+ = d_- = \frac{|1|}{\|w\|}$$

Y la suma de las dos será :

$$\frac{2}{\|w\|}$$



# Maquinas de soporte vectorial lineales

Se busca maximizar  $\frac{2}{\|\mathbf{w}\|}$  que es lo mismo que minimizar  $\|\mathbf{w}\|^2$

Sujeto a  $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1$

Este es un problema que en optimización se conoce como:

programación cuadrática: [https://en.wikipedia.org/wiki/Quadratic\\_programming](https://en.wikipedia.org/wiki/Quadratic_programming)

Puede ser resuelto mediante multiplicadores de Lagrange ( $\alpha_i$ ).

$$L_P \equiv \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^1 \alpha_i y_i (\mathbf{w} \cdot \mathbf{x}_i + b) + \sum_{i=1}^1 \alpha_i$$

[https://es.wikipedia.org/wiki/Multiplicadores\\_de\\_Lagrange#Ejemplo\\_2](https://es.wikipedia.org/wiki/Multiplicadores_de_Lagrange#Ejemplo_2)

# Maquinas de soporte vectorial lineales

También puede ser hallado en términos de los vectores de soporte, mediante la representación dual, Haciendo que los gradientes de  $L_D$  respecto a  $\mathbf{w}$  y  $b$  sean cero, minimizando  $L_D$  con las restricciones (1) y (2)


$$\begin{aligned} (1) \quad \mathbf{w} &= \sum_i \alpha_i y_i \mathbf{x}_i \\ (2) \quad \sum_i \alpha_i y_i &= 0 \end{aligned} \quad L_D = \sum_i \alpha_i - \frac{1}{2} \sum_i \alpha_i \alpha_j y_i y_j \mathbf{x}_i \cdot \mathbf{x}_j$$

- Los  $\mathbf{x}_i$  con  $\alpha_i$  no nulos son llamados vectores de soporte (*support vectors*) (VS)

# Maquinas de soporte vectorial lineales

## Caso no separable

En este caso se permite cierto error en la clasificación.




# Maquinas de soporte vectorial NO lineales

Se puede mejorar a este clasificador lineal aplicando el “truco del kernel”

El resultado del algoritmo es similar, excepto que cada producto punto es reemplazado por una función kernel no lineal



# Maquinas de soporte vectorial NO lineales




<http://www.youtube.com/watch?v=3liCbRZPrZA>

$$\begin{aligned} \max. \quad W(\alpha) &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ &\quad \downarrow \\ \max. \quad W(\alpha) &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \end{aligned}$$

# Maquinas de soporte vectorial NO lineales

Polinomial (in homogéneo):


$$k(\mathbf{x}, \mathbf{x}') = (\mathbf{x} \cdot \mathbf{x}' + 1)^d$$



# Maquinas de soporte vectorial NO lineales

Función de Base Radial



$$k(\mathbf{x}, \mathbf{x}') = e^{(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)} \text{ para } \gamma > 0$$



# Maquinas de soporte vectorial NO lineales

Función de Base Radial

$$k(\mathbf{x}, \mathbf{x}') = e^{(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)} \text{ para } \gamma > 0$$







# Maquinas de soporte vectorial NO lineales

Tangente Hiperbólica

$k(\mathbf{x}, \mathbf{x}') = \tanh(\gamma \mathbf{x} \cdot \mathbf{x}' + c)$  para algunos  $\gamma > 0$  y  $c > 0$



# Bibliografía

- En memoria del profesor Patrick Winston. [https://en.wikipedia.org/wiki/Patrick\\_Winston](https://en.wikipedia.org/wiki/Patrick_Winston)
- Corinna Cortes and V. Vapnik, "Support-Vector Networks", Machine Learning, 20, 1995. Disponible en <http://homepages.rpi.edu/~bennek/class/mml/papers/svn.pdf>
- Christopher J. C. Burges. "A Tutorial on Support Vector Machines for Pattern Recognition". Data Mining and Knowledge Discovery 2:121–167, 1998. Disponible en <https://www.microsoft.com/en-us/research/wp-content/uploads/2016/02/svmtutorial.pdf>
- A Library for Support Vector Machines aplicación en línea <http://www.csie.ntu.edu.tw/~cjlin/libsvm/>
- 16. Learning: Support Vector Machines [https://www.youtube.com/watch?v=\\_PwhiWxHK8o](https://www.youtube.com/watch?v=_PwhiWxHK8o)
- CVM Applet. aplicación en línea <http://www.eee.metu.edu.tr/~alatan/Courses/Demo/AppletSVM.html>
- Bases para el código de ejemplo en Opencv tomado de <http://opencv.jp/sample/svm.html> “en japonés”
- Support Vector Machine Disponible en [http://en.wikipedia.org/wiki/Support\\_vector\\_machine](http://en.wikipedia.org/wiki/Support_vector_machine)
- SVM with polynomial kernel visualization disponible en <http://www.youtube.com/watch?v=3liCbRZPrZA>
- Excelente video resumiendo el concepto: <https://www.youtube.com/watch?v=efR1C6CvhmE>